

# RPCA via ScaledGD

Zebediah

2024 年 6 月 25 日

## 目录

<b>1</b>	<b>记号、定义和性质</b>	<b>1</b>
1.1	记号	1
1.2	定义	1
1.3	性质	2
<b>2</b>	<b>提出的算法</b>	<b>3</b>
2.1	主要方法	3
2.2	主要结果	4
<b>3</b>	<b>定理 1 的证明</b>	<b>5</b>
3.1	归纳: 局部收缩	5
3.2	谱初始化	5
<b>4</b>	<b>实验结果简述</b>	<b>6</b>

论文: Fast and Provable Tensor Robust Principal Component Analysis via Scaled Gradient Descent, 作者为 Harry Dong, Tian Tong, Cong Ma, Yuejie Chi.

这篇文章主要研究张量鲁棒主成分分析 (RPCA), 旨在从被稀疏张量  $\mathcal{S}$  所污染的观测值  $\mathcal{Y}$  中恢复出一个低秩张量  $\mathcal{X}_*$ , 即

$$\mathcal{Y} = \mathcal{X}_* + \mathcal{S}_*, \quad (0.1)$$

其中  $\mathcal{S}_* \in \mathbb{R}^{n_1 \times n_2 \times n_3}$  是一个稀疏张量.

## 1 记号、定义和性质

### 1.1 记号

对于三阶张量  $\mathcal{X}_* \in \mathbb{R}^{n_1 \times n_2 \times n_3}$ , 我们称  $\mathcal{X}_*$  是低秩的如果它可以分解为

$$\mathcal{X}_* = \left( \mathbf{U}_*^{(1)}, \mathbf{U}_*^{(2)}, \mathbf{U}_*^{(3)} \right) \cdot \mathcal{G}_*, \quad (1.1)$$

其中  $\mathbf{U}_*^{(1)} \in \mathbb{R}^{n_1 \times r_1}$ ,  $\mathbf{U}_*^{(2)} \in \mathbb{R}^{n_2 \times r_2}$ ,  $\mathbf{U}_*^{(3)} \in \mathbb{R}^{n_3 \times r_3}$  为因子矩阵,  $\mathcal{G}_* \in \mathbb{R}^{r_1 \times r_2 \times r_3}$  为核张量,  $\{r_i\}_{i=1}^3$  为每个模态对应的秩. 等价地有

$$[\mathcal{X}]_{i_1, i_2, i_3} = \sum_{j_1=1}^{r_1} \sum_{j_2=1}^{r_2} \sum_{j_3=1}^{r_3} [\mathbf{U}^{(1)}]_{i_1, j_1} [\mathbf{U}^{(2)}]_{i_2, j_2} [\mathbf{U}^{(3)}]_{i_3, j_3} [\mathcal{G}]_{j_1, j_2, j_3}. \quad (1.2)$$

如果我们沿着每个模态将张量展平, 那么得到的矩阵都是低秩的:

$$r_1 = \text{rank}(\mathcal{M}_1(\mathcal{X}_*)), \quad r_2 = \text{rank}(\mathcal{M}_2(\mathcal{X}_*)), \quad r_3 = \text{rank}(\mathcal{M}_3(\mathcal{X}_*)), \quad (1.3)$$

其中  $\mathcal{M}_k(\cdot)$  表示对张量沿第  $k$  个模态的矩阵化 ( $k = 1, 2, 3$ ). 换句话说,  $\mathbf{r} = (r_1, r_2, r_3)$  是  $\mathcal{X}_*$  的多线性秩, 且通常取  $r_k \ll n_k$ , 记  $n := \max_k n_k$ ,  $r := \max_k r_k$ .

此外, 对于张量  $\mathcal{X} \in \mathbb{R}^{n_1 \times n_2 \times n_3}$ , 其高阶奇异值分解 (HOSVD)  $\mathcal{H}_r(\mathcal{X})$  写作

$$\mathcal{H}_r(\mathcal{X}) = \left( \mathbf{U}^{(1)}, \mathbf{U}^{(2)}, \mathbf{U}^{(3)}, \mathcal{G} \right). \quad (1.4)$$

### 1.2 定义

**定义 1 (非相干性)** 张量  $\mathcal{X}_*$  的非相干参数  $\mu$  定义为

$$\mu := \max_k \left\{ \frac{n_k}{r_k} \left\| \mathbf{U}_*^{(k)} \right\|_{2, \infty}^2 \right\}. \quad (1.5)$$

非相干参数大致衡量了  $\mathcal{X}_*$  的能量在其条目上的扩散程度——当  $\mu$  越小时, 能量越分散. 此外, 我们定义了一个新的条件数概念, 用于衡量真实张量  $\mathcal{X}_*$  的条件情况, 这比之前使用的概念要弱:

定义 2 (条件数) 张量  $\mathcal{X}_\star$  的条件数  $\kappa$  定义为

$$\kappa := \frac{\min_k \sigma_{\max}(\mathcal{M}_k(\mathcal{X}_\star))}{\min_k \sigma_{\min}(\mathcal{M}_k(\mathcal{X}_\star))}, \quad (1.6)$$

其中

$$\sigma_{\min}(\mathcal{X}_\star) = \min_k \sigma_{\min}(\mathcal{M}_k(\mathcal{X}_\star)) \quad (1.7)$$

为  $\mathcal{X}_\star$  的最小非零奇异值.

定义 3 ( $\alpha$  分数稀疏性) 污染张量  $\mathcal{S}_\star$  是  $\alpha$  分数稀疏的, i.e.,  $\mathcal{S}_\star \in \mathcal{S}_\alpha$ , 其中

$$\mathcal{S}_\alpha := \{\mathcal{S} \in \mathbb{R}^{n_1 \times n_2 \times n_3} : \|\mathcal{S}_{i_1, i_2, :}\|_0 \leq \alpha n_3, \|\mathcal{S}_{i_1, :, i_3}\|_0 \leq \alpha n_2, \|\mathcal{S}_{:, i_2, i_3}\|_0 \leq \alpha n_1, \forall 1 \leq i_k \leq n_k, k = 1, 2, 3\}.$$

定义 4 (软阈值算子) 对于三阶张量  $\mathcal{X}$ , 软阈值算子  $\mathcal{T}_\zeta(\cdot) : \mathbb{R}^{n_1 \times n_2 \times n_3} \mapsto \mathbb{R}^{n_1 \times n_2 \times n_3}$  定义为

$$[\mathcal{T}_\zeta(\mathcal{X})]_{i_1, i_2, i_3} := \text{sgn}([\mathcal{X}]_{i_1, i_2, i_3}) \cdot \max(0, |[\mathcal{X}]_{i_1, i_2, i_3}| - \zeta). \quad (1.8)$$

定义 5 (距离度量) 设  $\mathbf{F} := (\mathbf{U}^{(1)}, \mathbf{U}^{(2)}, \mathbf{U}^{(3)}, \mathcal{G})$ ,  $\mathbf{F}_\star := (\mathbf{U}_\star^{(1)}, \mathbf{U}_\star^{(2)}, \mathbf{U}_\star^{(3)}, \mathcal{G}_\star)$ , 定义

$$\text{dist}^2(\mathbf{F}, \mathbf{F}_\star) := \inf_{\mathbf{Q}^{(k)} \in \text{GL}(r_k)} \sum_{k=1}^3 \left\| \left( \mathbf{U}^{(k)} \mathbf{Q}^{(k)} - \mathbf{U}_\star^{(k)} \right) \boldsymbol{\Sigma}_\star^{(k)} \right\|_{\text{F}}^2 + \left\| \left( \left( \mathbf{Q}^{(1)} \right)^{-1}, \left( \mathbf{Q}^{(2)} \right)^{-1}, \left( \mathbf{Q}^{(3)} \right)^{-1} \right) \cdot \mathcal{G} - \mathcal{G}_\star \right\|_{\text{F}}^2,$$

其中  $\boldsymbol{\Sigma}_\star^{(k)}$  是  $\mathcal{M}_k(\mathcal{X}_\star)$  的奇异值矩阵,  $k = 1, 2, 3$ . 此外, 如果上确界在  $\{\mathbf{Q}^{(k)}\}_{k=1}^3$  处达到, 它们被称为  $\mathbf{F}$  和  $\mathbf{F}_\star$  之间的最优对齐矩阵.

### 1.3 性质

多线性乘法具有几个很好的性质, 其中一个重要的性质是, 对于任意的  $\mathbf{B}^{(k)} \in \mathbb{R}^{r_k \times r_k}$ ,  $k = 1, 2, 3$ , 有

$$\left( \mathbf{U}^{(1)} \mathbf{B}^{(1)}, \mathbf{U}^{(2)} \mathbf{B}^{(2)}, \mathbf{U}^{(3)} \mathbf{B}^{(3)} \right) \cdot \mathcal{G} = \left( \mathbf{U}^{(1)}, \mathbf{U}^{(2)}, \mathbf{U}^{(3)} \right) \cdot \left( \left( \mathbf{B}^{(1)}, \mathbf{B}^{(2)}, \mathbf{B}^{(3)} \right) \cdot \mathcal{G} \right). \quad (1.9)$$

因此对于  $\mathbf{Q}^{(k)} \in \text{GL}(r_k)$ ,  $k = 1, 2, 3$ , 有

$$\left( \mathbf{U}^{(1)}, \mathbf{U}^{(2)}, \mathbf{U}^{(3)} \right) \cdot \mathcal{G} = \left( \mathbf{U}^{(1)} \mathbf{Q}^{(1)}, \mathbf{U}^{(2)} \mathbf{Q}^{(2)}, \mathbf{U}^{(3)} \mathbf{Q}^{(3)} \right) \cdot \mathcal{G}_{\mathbf{Q}},$$

其中  $\mathcal{G}_{\mathbf{Q}} = \left( \left( \mathbf{Q}^{(1)} \right)^{-1}, \left( \mathbf{Q}^{(2)} \right)^{-1}, \left( \mathbf{Q}^{(3)} \right)^{-1} \right) \cdot \mathcal{G}$ , 即 Tucker 分解不是唯一的.

此外, 如果我们沿不同的模展平张量  $\mathcal{X}$ , 得到的矩阵遵循以下低秩分解:

$$\mathcal{M}_1(\mathcal{X}) = \mathbf{U}^{(1)} \mathcal{M}_1(\mathcal{G}) \left( \mathbf{U}^{(3)} \otimes \mathbf{U}^{(2)} \right)^\top = \mathbf{U}^{(1)} \check{\mathbf{U}}^{(1)\top}, \check{\mathbf{U}}^{(1)} := \left( \mathbf{U}^{(3)} \otimes \mathbf{U}^{(2)} \right) \mathcal{M}_1(\mathcal{G})^\top, \quad (1.10)$$

$$\mathcal{M}_2(\mathcal{X}) = \mathbf{U}^{(2)} \mathcal{M}_2(\mathcal{G}) \left( \mathbf{U}^{(3)} \otimes \mathbf{U}^{(1)} \right)^\top = \mathbf{U}^{(2)} \check{\mathbf{U}}^{(2)\top}, \check{\mathbf{U}}^{(2)} := \left( \mathbf{U}^{(3)} \otimes \mathbf{U}^{(1)} \right) \mathcal{M}_2(\mathcal{G})^\top, \quad (1.11)$$

$$\mathcal{M}_3(\mathcal{X}) = \mathbf{U}^{(3)} \mathcal{M}_3(\mathcal{G}) \left( \mathbf{U}^{(2)} \otimes \mathbf{U}^{(1)} \right)^\top = \mathbf{U}^{(3)} \check{\mathbf{U}}^{(3)\top}, \check{\mathbf{U}}^{(3)} := \left( \mathbf{U}^{(2)} \otimes \mathbf{U}^{(1)} \right) \mathcal{M}_3(\mathcal{G})^\top. \quad (1.12)$$

给定两个张量  $\mathcal{A}$  和  $\mathcal{B}$ , 它们的内积定义为  $\langle \mathcal{A}, \mathcal{B} \rangle = \sum_{i_1, i_2, i_3} \mathcal{A}_{i_1, i_2, i_3} \mathcal{B}_{i_1, i_2, i_3}$ . 内积满足以下性质:

$$\left\langle \left( U^{(1)}, U^{(2)}, U^{(3)} \right) \cdot \mathcal{G}, \mathcal{X} \right\rangle = \left\langle \mathcal{G}, \left( U^{(1)\top}, U^{(2)\top}, U^{(3)\top} \right) \cdot \mathcal{X} \right\rangle. \quad (1.13)$$

将张量  $\|\mathcal{X}\|$  的 Frobenius 范数和  $\ell_\infty$  范数分别表示为  $\|\mathcal{X}\|_F = \sqrt{\langle \mathcal{X}, \mathcal{X} \rangle}$  和  $\|\mathcal{X}\|_\infty = \max_{i_1, i_2, i_3} |\mathcal{X}_{i_1, i_2, i_3}|$ , 则对  $\mathbf{Q}_k \in \mathbb{R}^{r_k \times r_k}, k = 1, 2, 3$  有:

$$\|(\mathbf{Q}_1, \mathbf{Q}_2, \mathbf{Q}_3) \cdot \mathcal{G}\|_F \leq \|\mathbf{Q}_1\| \|\mathbf{Q}_2\| \|\mathbf{Q}_3\| \|\mathcal{G}\|_F. \quad (1.14)$$

## 2 提出的算法

### 2.1 主要方法

我们考虑的目标函数为

$$\mathcal{L}(\mathbf{F}, \mathcal{S}) := \frac{1}{2} \left\| \left( U^{(1)}, U^{(2)}, U^{(3)} \right) \cdot \mathcal{G} + \mathcal{S} - \mathcal{Y} \right\|_F^2, \quad (2.1)$$

其中  $\mathbf{F} = (U^{(1)}, U^{(2)}, U^{(3)}, \mathcal{G})$ .

在每次迭代开始时, 我们通过对观测残差阈值化来更新污染张量  $\mathcal{S}$ :

$$\mathcal{S}_{t+1} = \mathcal{T}_{\zeta_{t+1}} \left( \mathcal{Y} - \left( U_t^{(1)}, U_t^{(2)}, U_t^{(3)} \right) \cdot \mathcal{G}_t \right), \quad t = 0, 1, \dots. \quad (2.2)$$

随着数据张量  $\mathcal{X}_t = \left( U_t^{(1)}, U_t^{(2)}, U_t^{(3)} \right) \cdot \mathcal{G}_t$  的估计变得更加准确, 观测残差与腐蚀项变得更加一致. 此外, 利用 ScaledGD, 我们提出通过沿缩放梯度方向迭代下降来更新低秩张量因子:

$$U_{t+1}^{(k)} = U_t^{(k)} - \eta \nabla_{U_t^{(k)}} \mathcal{L}(\mathbf{F}_t, \mathcal{S}_{t+1}) \left( \check{U}_t^{(k)\top} \check{U}_t^{(k)} \right)^{-1}, \quad k = 1, 2, 3, \quad (2.3)$$

$$\mathcal{G}_{t+1} = \mathcal{G}_t - \eta \left( \left( U_t^{(1)\top} U_t^{(1)} \right)^{-1}, \left( U_t^{(2)\top} U_t^{(2)} \right)^{-1}, \left( U_t^{(3)\top} U_t^{(3)} \right)^{-1} \right) \cdot \nabla_{\mathcal{G}_t} \mathcal{L}(\mathbf{F}_t, \mathcal{S}_{t+1}). \quad (2.4)$$

其中  $\mathbf{F}_t = (U_t^{(1)}, U_t^{(2)}, U_t^{(3)}, \mathcal{G}_t)$  是第  $t$  次迭代中张量因子的估计,  $\eta > 0$  是学习率, 且

$$\check{U}_t^{(1)} = \left( U_t^{(3)} \otimes U_t^{(2)} \right) \mathcal{M}_1(\mathcal{G}_t)^\top, \check{U}_t^{(2)} = \left( U_t^{(3)} \otimes U_t^{(1)} \right) \mathcal{M}_2(\mathcal{G}_t)^\top, \check{U}_t^{(3)} = \left( U_t^{(2)} \otimes U_t^{(1)} \right) \mathcal{M}_3(\mathcal{G}_t)^\top$$

用于构造梯度预条件方向,  $\otimes$  表示 Kronecker 积. ScaledGD 平衡了张量因子以找到更好的下降方向, 这在病态张量中表现更加显著. 事实上, 在病态问题中, 普通梯度下降的收敛率显著退化, 而 ScaledGD 能够在不考虑条件数的情况下仍保持线性收敛.

## 2.2 主要结果

直接计算 (2.3) 和 (2.4) 得

$$\begin{aligned} \mathbf{U}_{t+1}^{(k)} &= \mathbf{U}_t^{(k)} - \eta \nabla_{\mathbf{U}_t^{(k)}} \mathcal{L}(\mathbf{F}_t, \mathbf{S}_{t+1}) \left( \check{\mathbf{U}}_t^{(k)\top} \check{\mathbf{U}}_t^{(k)} \right)^{-1} \\ &= (1 - \eta) \mathbf{U}_t^{(k)} - \eta (\mathcal{M}_k(\mathbf{S}_{t+1}) - \mathcal{M}_k(\mathbf{Y})) \check{\mathbf{U}}_t^{(k)} \left( \check{\mathbf{U}}_t^{(k)\top} \check{\mathbf{U}}_t^{(k)} \right)^{-1}, \quad k = 1, 2, 3 \end{aligned} \quad (2.5)$$

以及

$$\begin{aligned} \mathbf{G}_{t+1} &= \mathbf{G}_t - \eta \left( \left( \mathbf{U}_t^{(1)\top} \mathbf{U}_t^{(1)} \right)^{-1}, \left( \mathbf{U}_t^{(2)\top} \mathbf{U}_t^{(2)} \right)^{-1}, \left( \mathbf{U}_t^{(3)\top} \mathbf{U}_t^{(3)} \right)^{-1} \right) \cdot \nabla_{\mathbf{G}_t} \mathcal{L}(\mathbf{F}_t, \mathbf{S}_{t+1}) \\ &= (1 - \eta) \mathbf{G}_t - \eta \left( \left( \mathbf{U}_t^{(1)\top} \mathbf{U}_t^{(1)} \right)^{-1} \mathbf{U}_t^{(1)\top}, \left( \mathbf{U}_t^{(2)\top} \mathbf{U}_t^{(2)} \right)^{-1} \mathbf{U}_t^{(2)\top}, \left( \mathbf{U}_t^{(3)\top} \mathbf{U}_t^{(3)} \right)^{-1} \mathbf{U}_t^{(3)\top} \right) \cdot (\mathbf{S}_{t+1} - \mathbf{Y}). \end{aligned} \quad (2.6)$$

算法流程如下所示:

---

**Algorithm 1** ScaledGD for tensor robust principal component analysis

---

- 1: **Input:** the observed tensor  $\mathbf{Y}$ , the multilinear rank  $\mathbf{r}$ , learning rate  $\eta$ , and  $\{\zeta_t\}_{t=0}^T$ .
  - 2: **Initialization:**  $\mathbf{S}_0 = \mathcal{T}_{\mathbf{S}_0}(\mathbf{Y})$  and  $(\mathbf{U}_0^{(1)}, \mathbf{U}_0^{(2)}, \mathbf{U}_0^{(3)}, \mathbf{G}_0) = \mathcal{H}_{\mathbf{r}}(\mathbf{Y} - \mathbf{S}_0)$
  - 3: **for**  $t = 0, 1, \dots, T - 1$  **do**
  - 4:   Update the corruption tensor  $\mathbf{S}_{t+1}$  via (2.2);
  - 5:   Update the tensor factors  $\mathbf{F}_{t+1} = (\mathbf{U}_{t+1}^{(1)}, \mathbf{U}_{t+1}^{(2)}, \mathbf{U}_{t+1}^{(3)}, \mathbf{G}_{t+1})$  via (2.5) and (2.6).
  - 6: **end for**
  - 7: **Output:** the tensor factors  $\mathbf{F}_T = (\mathbf{U}_T^{(1)}, \mathbf{U}_T^{(2)}, \mathbf{U}_T^{(3)}, \mathbf{G}_T)$ .
- 

**定理 1** 设  $\mathbf{Y} = \mathbf{X}_* + \mathbf{S}_* \in \mathbb{R}^{n_1 \times n_2 \times n_3}$ , 其中  $\mathbf{X}_*$  是  $\mu$ -非相干且具有多线性秩为  $\mathbf{r} = (r_1, r_2, r_3)$  的张量,  $\mathbf{S}_*$  是  $\alpha$ -稀疏的. 假设阈值  $\{\zeta_k\}_{k=0}^\infty$  满足  $\|\mathbf{X}_*\|_\infty \leq \zeta_0 \leq 2\|\mathbf{X}_*\|_\infty$  且  $\zeta_{t+1} = \rho\zeta_t, t \geq 1$ , 适当选取  $\zeta_1 = 8\sqrt{\frac{\mu^3 r_1 r_2 r_3}{n_1 n_2 n_3}} \sigma_{\min}(\mathbf{X}_*)$ ,  $\frac{1}{7} \leq \eta \leq \frac{1}{4}$ ,  $\rho = (1 - 0.45\eta)$ , 则对所有  $t \geq 0$ , 迭代  $\mathbf{X}_t = (\mathbf{U}_t^{(1)}, \mathbf{U}_t^{(2)}, \mathbf{U}_t^{(3)}) \cdot \mathbf{G}_t$  满足

$$\|\mathbf{X}_t - \mathbf{X}_*\|_F \leq 0.03\rho^t \sigma_{\min}(\mathbf{X}_*), \quad (2.7)$$

$$\|\mathbf{X}_t - \mathbf{X}_*\|_\infty \leq 8\rho^t \sqrt{\frac{\mu^3 r_1 r_2 r_3}{n_1 n_2 n_3}} \sigma_{\min}(\mathbf{X}_*), \quad (2.8)$$

$$\|\mathbf{S}_t - \mathbf{S}_*\|_\infty \leq 16\rho^t \sqrt{\frac{\mu^3 r_1 r_2 r_3}{n_1 n_2 n_3}} \sigma_{\min}(\mathbf{X}_*), \quad (2.9)$$

其中扰动水平满足  $\alpha \leq \frac{c_0}{\mu^2 r_1 r_2 r_3 \kappa}$ ,  $c_0 > 0$  是足够小的常数. 选择  $\rho$  的值是为了简化证明, 不应视为最佳收敛速度.

### 3 定理 1 的证明

定理 1 的证明主要使用归纳假设. 我们首先给定以下假设:

$$\text{dist}(\mathbf{F}_t, \mathbf{F}_\star) \leq \epsilon_0 \rho^t \sigma_{\min}(\mathcal{X}_\star), \quad (3.1)$$

$$\max_k \left\{ \sqrt{\frac{n_k}{r_k}} \left\| \left( \mathbf{U}_t^{(k)} \mathbf{Q}_t^{(k)} - \mathbf{U}_\star^{(k)} \right) \boldsymbol{\Sigma}_\star^{(k)} \right\|_{2,\infty} \right\} \leq \rho^t \sqrt{\mu} \sigma_{\min}(\mathcal{X}_\star), \quad (3.2)$$

其中  $\rho = 1 - 0.45\eta$ ,  $\epsilon_0 < 0.01$  是充分小的常数,  $\{\mathbf{Q}_t^{(k)}\}_{k=1}^3$  是  $\mathbf{F}_t$  和  $\mathbf{F}_\star$  的最优对齐矩阵 (作用是使得两个矩阵或张量在某种变换下尽可能一致).

#### 3.1 归纳: 局部收缩

下面的引理 1 保证了距离度量的收缩, 引理 2 则建立了非相干性度量的收缩, 因此我们可以反复应用引理 1 和引理 2 进行归纳.

**引理 1 (距离收缩)** 设  $\mathcal{Y} = \mathcal{X}_\star + \mathcal{S}_\star \in \mathbb{R}^{n_1 \times n_2 \times n_3}$ , 其中  $\mathcal{X}_\star$  是  $\mu$ -非相干且具有多线性秩  $\mathbf{r} = (r_1, r_2, r_3)$  的张量,  $\mathcal{S}_\star$  是  $\alpha$ -稀疏的. 令  $\mathbf{F}_t := (\mathbf{U}_t^{(1)}, \mathbf{U}_t^{(2)}, \mathbf{U}_t^{(3)}, \mathcal{G}_t)$  为算法 1 的第  $t$  次迭代. 如果假设 (3.1), (3.2) 在第  $t$  次迭代中成立, 设  $\alpha \leq \frac{c_0 \rho}{\sqrt{\mu^3 r_1 r_2 r_3 r}}$ ,  $c_0$  为某个足够小的常数, 在定理 1 中的  $\zeta_{t+1}$  的选取下, 只要  $\eta \leq 1/4$ , 那么第  $(t+1)$  次迭代  $\mathbf{F}_{t+1}$  满足

$$\text{dist}(\mathbf{F}_{t+1}, \mathbf{F}_\star) \leq \epsilon_0 \rho^{t+1} \sigma_{\min}(\mathcal{X}_\star).$$

**引理 2 (非相干性收缩)** 设  $\mathcal{Y} = \mathcal{X}_\star + \mathcal{S}_\star \in \mathbb{R}^{n_1 \times n_2 \times n_3}$ , 其中  $\mathcal{X}_\star$  是  $\mu$ -非相干且具有多线性秩  $\mathbf{r} = (r_1, r_2, r_3)$  的张量,  $\mathcal{S}_\star$  是  $\alpha$ -稀疏的. 令  $\mathbf{F}_t := (\mathbf{U}_t^{(1)}, \mathbf{U}_t^{(2)}, \mathbf{U}_t^{(3)}, \mathcal{G}_t)$  为算法 1 的第  $t$  次迭代. 如果假设 (3.1), (3.2) 在第  $t$  次迭代中成立, 设  $\alpha \leq \frac{c_1}{\mu^2 r_1 r_2 r_3}$ ,  $c_1$  为某个足够小的常数, 在定理 1 中的  $\zeta_{t+1}$  的选取下, 只要  $1/7 \leq \eta \leq 1/4$ , 那么第  $(t+1)$  次迭代  $\mathbf{F}_{t+1}$  满足

$$\max_k \left\{ \sqrt{\frac{n_k}{r_k}} \left\| \left( \mathbf{U}_{t+1}^{(k)} \mathbf{Q}_{t+1}^{(k)} - \mathbf{U}_\star^{(k)} \right) \boldsymbol{\Sigma}_\star^{(k)} \right\|_{2,\infty} \right\} \leq \rho^{t+1} \sqrt{\mu} \sigma_{\min}(\mathcal{X}_\star),$$

其中  $\{\mathbf{Q}_t^{(k)}\}_{k=1}^3$  是  $\mathbf{F}_t$  和  $\mathbf{F}_\star$  的最优对齐矩阵.

#### 3.2 谱初始化

为了建立归纳假设, 我们仍需要检查谱初始化. 以下引理表明, 谱初始化在  $t = 0$  时也满足归纳假设 (3.1), (3.2).

**引理 3 (初始化时的距离)** 设  $\mathcal{Y} = \mathcal{X}_\star + \mathcal{S}_\star \in \mathbb{R}^{n_1 \times n_2 \times n_3}$ , 其中  $\mathcal{X}_\star$  是  $\mu$ -非相干且具有多线性秩  $\mathbf{r} = (r_1, r_2, r_3)$  的张量,  $\mathcal{S}_\star$  是  $\alpha$ -稀疏的. 令  $\mathbf{F}_0 := (\mathbf{U}_0^{(1)}, \mathbf{U}_0^{(2)}, \mathbf{U}_0^{(3)}, \mathcal{G}_0)$  为谱初始化的输出, 其中阈值满足  $\|\mathcal{X}_\star\|_\infty \leq \zeta_0 \leq 2\|\mathcal{X}_\star\|_\infty$ . 对某个充分小的常数  $c_0 > 0$ , 如果  $\alpha \leq \frac{c_0}{\sqrt{\mu^3 r_1 r_2 r_3 r_K}}$ , 我们有

$$\text{dist}(\mathbf{F}_0, \mathbf{F}_\star) \leq 54.1 c_0 \sigma_{\min}(\mathcal{X}_\star).$$

**引理 4 (初始化时的不相关性)** 设  $\mathcal{Y} = \mathcal{X}_* + \mathcal{S}_* \in \mathbb{R}^{n_1 \times n_2 \times n_3}$ , 其中  $\mathcal{X}_*$  是  $\mu$ -非相干且具有多线性秩  $\mathbf{r} = (r_1, r_2, r_3)$  的张量,  $\mathcal{S}_*$  是  $\alpha$ -稀疏的. 令  $\mathbf{F}_0 := (\mathbf{U}_0^{(1)}, \mathbf{U}_0^{(2)}, \mathbf{U}_0^{(3)}, \mathbf{G}_0)$  为谱初始化的输出, 其中阈值满足  $\|\mathcal{X}_*\|_\infty \leq \zeta_0 \leq 2\|\mathcal{X}_*\|_\infty$ . 对某个充分小的常数  $c_0 > 0$ , 如果  $\alpha \leq \frac{c_0}{\mu^2 r_1 r_2 r_3 \kappa}$ , 那么谱初始化满足非相干性条件

$$\max_k \left\{ \sqrt{\frac{n_k}{r_k}} \left\| \left( \mathbf{U}_0^{(k)} \mathbf{Q}_0^{(k)} - \mathbf{U}_*^{(k)} \right) \boldsymbol{\Sigma}_*^{(k)} \right\|_{2,\infty} \right\} \leq \sqrt{\mu} \sigma_{\min}(\mathcal{X}_*),$$

其中  $\{\mathbf{Q}_0^{(k)}\}_{k=1}^3$  是  $\mathbf{F}_0$  和  $\mathbf{F}_*$  的最优对齐矩阵.

上述引理的证明可参见文章的附录.

## 4 实验结果简述

这部分内容我将直接使用简洁的语言叙述, 若要深入了解细节可参考原文. 实验主要包含以下三个:

- **随机生成三阶张量实验.** 此实验随机生成了一个大小为  $(100, 100, 100)$  的张量, 并给予水平为  $\alpha$  污染. 并与 RiemannianGD 算法进行了比较, 发现 ScaledGD 每次迭代成本小, 并且速度要快得多.
- **MNIST 实验.** 此实验选取 MNIST 库中标签为 2 的所有图像作为输入, 即输入的张量是大小为  $(5958, 28, 28)$  的张量. 实验分为三组: 一是添加 70% 椒盐噪声; 二是随机替换其中 500 张图像; 三是添加 50% 椒盐噪声并随机替换其中 500 张图像. 实验结果显示在所有情况下, ScaledGD 比 TNN 更准确地恢复了与正确数字对应的低秩部分. 此外, ScaledGD 修正了形状奇怪或异常的数字, 使低秩分量更加均匀, 但 TNN 在低秩输出中大多保留了这些情况. 更重要的是, ScaledGD 作为一种可缩放的非凸方法运行得要快得多, 而 TNN 使用凸优化的计算成本更高.
- **视频背景减除实验.** 此实验将 ScaledGD 应用于使用 VIRAT 数据集集中的视频进行背景减除任务. 视频数据可以被视为一个跨越高度、宽度、帧以及场景中不同颜色通道的多维张量. 这里, 低秩张量对应于视频中的背景, 该背景在帧间是相对静止的, 而稀疏张量对应于包含移动物体的前景, 这些前景占用的像素数量很少. 一个合理的假设是, 对于对应于帧的模式, 背景张量是低秩的, 但在其他模式中是全秩的. 受到这一观察的启发, 可能会尝试选择性地仅更新核心张量和对应于帧模式的因子矩阵, 同时在谱初始化后保持其他因子矩阵不变. 实验结果表明, 跳过全秩因子矩阵的更新产生了质量上相似的结果, 同时每次迭代的速度显著提高了大约 4.6 到 5 倍.